

# Detecção de Fraudes Bancárias via Teoria dos Grafos

Superando as limitações dos sistemas relacionais na era digital.

Professor: Márcio de Medeiros Ribeiro

Integrantes:

- Pedro Henrique Freire Gama
- Pedro Affonso Lopes Dias
- Sofia Pacheco Rizzotto
- Vitor Gabriel da Silva Santos

# O Desafio da Fraude em Tempo Real

Fraudadores exploram vulnerabilidades com precisão, tornando a detecção tardia e o prejuízo inevitável. Bancos de dados relacionais são incapazes de mapear conexões ocultas em tempo real — criando a necessidade de uma nova abordagem estrutural.

## Adversários Especializados

Grupos organizados exploram brechas sistêmicas antes que qualquer alerta seja gerado.


## Limitação Relacional

Junções complexas e custosas impossibilitam análise de vínculos em tempo real.

## Solução em Grafos

Navegação por conexões na memória permite detecção imediata de padrões fraudulentos.

# Fraude de Primeira Ordem: Identidades Sintéticas



Fraudadores solicitam crédito sem garantia sem intenção de pagar, comportando-se como clientes legítimos até desaparecerem com os recursos.

- **10–20%** da dívida incobrável em grandes bancos dos EUA e Europa é fraude não classificada
- Relação **exponencial** entre participantes da quadrilha e valor total controlado
- Padrões de conexão revelam a rede — característica explorável por grafos

Figura 1: 2 pessoas compartilhando 2 dados e criando 4 identidades sintéticas. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

# O Gargalo Computacional do Modelo Relacional

Bancos relacionais exigem junções complexas e custosas — inviáveis em tempo real. Bancos em grafos navegam conexões na memória, permitindo consultas em quatro estágios críticos:

**01** — Criação da conta

**02** — Durante investigação

**03** — Atingimento do limite de crédito

**04** — Devolução de cheque sem fundos

Cada consulta navega apenas pelos vizinhos do nó — não varre o banco inteiro.




Figura 2: Subconjunto de uma rede de fraude, conforme modelado em um banco de dados gráfico. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

# E-commerce: Multi-Identities e Vínculos Digitais




Figura 5: Fraude de pagamento online originada de endereço IP. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB



## IP Compartilhado

Múltiplos usuários com transações no mesmo IP sugerem identidades falsas coordenadas.



## Cartão com Múltiplos Endereços

Um cartão associado a diferentes endereços de entrega indica uso fraudulento.



## Endereço com Múltiplos Cartões

Um endereço vinculado a vários cartões revela esquemas de multi-identidade.

Fraudadores criam múltiplas identidades para explorar sistemas de pagamento online. A relação esperada entre identificadores é **1:1** — desvios indicam fraude.

Verificações integradas a eventos de **login**, **pedido** e **registro de cartão** tornam o sistema altamente eficiente.

# Algoritmos de Mineração de Padrões (Graph Mining)

Alguns dos algoritmos existentes utilizados na descoberta desses dados destacam-se como:

## SUBGRAFO FREQUENTE

### gSpan

Descobre subestruturas recorrentes no grafo sem gerar candidatos. Atribui a cada subgrafo um código DFS mínimo único como rótulo canônico, permitindo identificar padrões de conexão que se repetem em diferentes partes do banco de dados.

**Aplicação real — Caso 1 (Identidades Sintéticas):** Identifica o padrão estrutural repetido de duas ou mais pessoas compartilhando telefone e endereço e ramificando múltiplos cartões e contas bancárias — o “molde” estrutural da quadrilha fraudulenta no grafo.

## INDEXAÇÃO POR SUBESTRUTURA

### gIndex

Usa subestruturas frequentes como índice de busca. Cada nó conhece seus próprios vizinhos diretamente por ponteiros físicos, dispensando varredura global dos dados — princípio da Index-Free Adjacency.

**Aplicação real — Caso 3 (E-commerce):** Indexa as relações entre IP, cartão de crédito e endereço de entrega e detecta instantaneamente quando a proporção 1:1 esperada entre esses identificadores é violada, no momento do login, do pedido ou do registro do cartão.

Esses dois algoritmos atuam em fases complementares: o gSpan encontra o padrão estrutural da fraude — o molde da quadrilha no grafo. O gIndex viabiliza a consulta em tempo real sem varredura global, tornando a detecção operacionalmente possível em escala bancária.

## Pseudocódigo — Detecção de Fraudes em Grafos

```
// 1. Modelagem: dados viram nós; vínculos viram arestas
FUNÇÃO inserirCliente(cliente, telefone, cpf, endereco):
  noC ← buscarOuCriar(cliente) // O(1) — ponteiro direto
  conectar(noC → telefone, "USA_TELEFONE")
  conectar(noC → endereco, "MORA_EM")
  conectar(noC → cpf, "TEM_CPF")
  RETORNA verificarFraude(noC) // dispara imediatamente

// 2. Detecção: BFS busca dados compartilhados entre identidades
FUNÇÃO verificarFraude(noOrigem):
  fila ← [noOrigem]; visitados ← ∅; suspeitos ← []
  ENQUANTO fila ≠ ∅:
    atual ← desenfileirar(fila)
    PARA CADA vizinho DE atual.arestas:
      SE vizinho ∉ visitados:
        marcar(visitados, vizinho)
        SE grau(vizinho) > LIMITE: adicionar(suspeitos)
        SE profundidade(vizinho) < 3: enfileirar(fila, vizinho)
  RETORNA suspeitos // O(V+E) local — não varre o banco inteiro
```

**Ponto-chave:** o grafo analisa apenas o subgrafo local do cliente — não o banco inteiro.

# Score de Risco e Acionamento

// 3. Quanto mais densa a rede, maior o risco

FUNÇÃO **calcularRisco**(componente):

risco ← **tamanho**(componente) × 0.4

+ **mediaGrau**(componente) × 0.4

+ **dadosCompartilhados**() × 0.2

RETORNA **normalizar**(risco, 0, 1) // saída: 0.0 a 1.0

// 4. Acionado em 4 momentos críticos do ciclo bancário

AO "CONTA\_CRIADA" → **verificarFraude**() // risco > 0.7 → bloquear

AO "LIMITE\_ATINGIDO" → **verificarFraude**() // risco > 0.5 → alertar

AO "CHEQUE\_DEVOLVIDO" → **identificarQuadrilha**() // abre investigação

AO "INVESTIGAÇÃO" → **extrairSubgrafo**(d=4)

// Eficiência:  $O(k^d)$  —  $k$ =grau médio,  $d$ =profundidade

// Exemplo:  $k=5$ ,  $d=3$  → apenas ~125 nós analisados por evento

// SQL equivalente exigiria JOINS recursivos em milhões de linhas

Os mesmos 4 gatilhos já mencionados no slide do Gargalo Relacional — agora implementados em código.



# O Futuro da Segurança Bancária

A transição do modelo relacional para grafos não é uma preferência técnica — é uma necessidade operacional diante da escala e velocidade do crime financeiro organizado.

## Modelo Relacional

- Junções complexas e custosas
- Detecção tardia, após o prejuízo
- Inviável em tempo real
- Fraudes classificadas erroneamente como dívida comum

## Banco de Dados em Grafo

- Navegação por ponteiros físicos via Index-Free Adjacency
- Detecção na criação da conta ou do pedido
- Complexidade linear  $O(V+E)$
- Intercepta a fraude antes do prejuízo se efetivar

Ao focar na relação entre os dados — e não nos registros isolados —, instituições financeiras conseguem interceptar fraudes complexas de identidade e e-commerce em tempo real, mitigando prejuízos antes mesmo que eles sejam consolidados.

# Fontes de Pesquisa e Referências

- Neo4j Team (2014). Fraud Detection Using GraphDB: Discovering Connections with Graph Database Technology. Available at: <https://we-yun.com/doc/neo4j-book/%E5%9B%BE%E6%95%B0%E6%8D%AE%E6%8D%AE%E5%BA%93%E5%9B%9B%E5%BA%94%E7%94%A8%E6%A1%8B%E4%BE%8B/Fraud%20Detection%20Using%20GraphDB%20-%202014.pdf>
- Kumar, N., & Singh, K. (2016). Analysis of Pattern Identification Using Graph Database for Fraud Detection. International Journal of Computer Science Journal, Vol. 9, No. 2. Available at: <https://www.computerscijournal.org/vol9no2/analysis-of-pattern-identification-using-graph-database-for-fraud-detection/>