

Detecção de Fraudes Bancárias via Teoria dos Grafos

Superando as limitações dos sistemas relacionais na era digital.

Professor: Márcio de Medeiros Ribeiro

Integrantes:

- Pedro Henrique Freire Gama
- Pedro Affonso Lopes Dias
- Sofia Pacheco Rizzotto
- Vitor Gabriel da Silva Santos

O Desafio da Fraude em Tempo Real

Fraudadores exploram vulnerabilidades com precisão, tornando a detecção tardia e o prejuízo inevitável. Bancos de dados relacionais são incapazes de mapear conexões ocultas em tempo real — criando a necessidade de uma nova abordagem estrutural.

Adversários Especializados

Grupos organizados exploram brechas sistêmicas antes que qualquer alerta seja gerado.


Limitação Relacional

Junções complexas e custosas impossibilitam análise de vínculos em tempo real.

Solução em Grafos

Navegação por conexões na memória permite detecção imediata de padrões fraudulentos.

Fraude de Primeira Ordem: Identidades Sintéticas



Fraudadores solicitam crédito sem garantia sem intenção de pagar, comportando-se como clientes legítimos até desaparecerem com os recursos.

- **10–20%** da dívida incobrável em grandes bancos dos EUA e Europa é fraude não classificada
- Relação **exponencial** entre participantes da quadrilha e valor total controlado
- Padrões de conexão revelam a rede — característica explorável por grafos

Figura 1: 2 pessoas compartilhando 2 dados e criando 4 identidades sintéticas. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

O Gargalo Computacional do Modelo Relacional

Bancos relacionais exigem junções complexas e custosas — inviáveis em tempo real. Bancos em grafos navegam conexões na memória, permitindo consultas em quatro estágios críticos:

01 — Criação da conta

02 — Durante investigação

03 — Atingimento do limite de crédito

04 — Devolução de cheque sem fundos

Cada consulta navega apenas pelos vizinhos do nó — não varre o banco inteiro.




Figura 2: Subconjunto de uma rede de fraude, conforme modelado em um banco de dados gráfico. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

E-commerce: Multi-Identities e Vínculos Digitais




Figura 5: Fraude de pagamento online originada de endereço IP. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB



IP Compartilhado

Múltiplos usuários com transações no mesmo IP sugerem identidades falsas coordenadas.



Cartão com Múltiplos Endereços

Um cartão associado a diferentes endereços de entrega indica uso fraudulento.



Endereço com Múltiplos Cartões

Um endereço vinculado a vários cartões revela esquemas de multi-identidade.

Fraudadores criam múltiplas identidades para explorar sistemas de pagamento online. A relação esperada entre identificadores é **1:1** — desvios indicam fraude.

Verificações integradas a eventos de **login**, **pedido** e **registro de cartão** tornam o sistema altamente eficiente.

Algoritmos de Mineração de Padrões (Graph Mining)

Alguns dos algoritmos existentes utilizados na descoberta desses dados destacam-se como:

SUBGRAFO FREQUENTE

gSpan

Descobre subestruturas recorrentes no grafo sem gerar candidatos. Atribui a cada subgrafo um código DFS mínimo único como rótulo canônico, permitindo identificar padrões de conexão que se repetem em diferentes partes do banco de dados.

Aplicação real — Caso 1 (Identidades Sintéticas): Identifica o padrão estrutural repetido de duas ou mais pessoas compartilhando telefone e endereço e ramificando múltiplos cartões e contas bancárias — o “molde” estrutural da quadrilha fraudulenta no grafo.

INDEXAÇÃO POR SUBESTRUTURA

gIndex

Usa subestruturas frequentes como índice de busca. Cada nó conhece seus próprios vizinhos diretamente por ponteiros físicos, dispensando varredura global dos dados — princípio da Index-Free Adjacency.

Aplicação real — Caso 3 (E-commerce): Indexa as relações entre IP, cartão de crédito e endereço de entrega e detecta instantaneamente quando a proporção 1:1 esperada entre esses identificadores é violada, no momento do login, do pedido ou do registro do cartão.

Esses dois algoritmos atuam em fases complementares: o gSpan encontra o padrão estrutural da fraude — o molde da quadrilha no grafo. O gIndex viabiliza a consulta em tempo real sem varredura global, tornando a detecção operacionalmente possível em escala bancária.

Pseudocódigo — Detecção de Fraudes em Grafos

```
// 1. Modelagem: dados viram nós; vínculos viram arestas
FUNÇÃO inserirCliente(cliente, telefone, cpf, endereco):
  noC ← buscarOuCriar(cliente) // O(1) — ponteiro direto
  conectar(noC → telefone, "USA_TELEFONE")
  conectar(noC → endereco, "MORA_EM")
  conectar(noC → cpf, "TEM_CPF")
  RETORNA verificarFraude(noC) // dispara imediatamente

// 2. Detecção: BFS busca dados compartilhados entre identidades
FUNÇÃO verificarFraude(noOrigem):
  fila ← [noOrigem]; visitados ← ∅; suspeitos ← []
  ENQUANTO fila ≠ ∅:
    atual ← desenfileirar(fila)
    PARA CADA vizinho DE atual.arestas:
      SE vizinho ∉ visitados:
        marcar(visitados, vizinho)
        SE grau(vizinho) > LIMITE: adicionar(suspeitos)
        SE profundidade(vizinho) < 3: enfileirar(fila, vizinho)
  RETORNA suspeitos // O(V+E) local — não varre o banco inteiro
```

Ponto-chave: o grafo analisa apenas o subgrafo local do cliente — não o banco inteiro.

Score de Risco e Acionamento

// 3. Quanto mais densa a rede, maior o risco

FUNÇÃO **calcularRisco**(componente):

risco ← **tamanho**(componente) × 0.4

+ **mediaGrau**(componente) × 0.4

+ **dadosCompartilhados**() × 0.2

RETORNA **normalizar**(risco, 0, 1) // saída: 0.0 a 1.0

// 4. Acionado em 4 momentos críticos do ciclo bancário

AO "CONTA_CRIADA" → **verificarFraude**() // risco > 0.7 → bloquear

AO "LIMITE_ATINGIDO" → **verificarFraude**() // risco > 0.5 → alertar

AO "CHEQUE_DEVOLVIDO" → **identificarQuadrilha**() // abre investigação

AO "INVESTIGAÇÃO" → **extrairSubgrafo**(d=4)

// Eficiência: $O(k^d)$ — k =grau médio, d =profundidade

// Exemplo: $k=5$, $d=3$ → apenas ~125 nós analisados por evento

// SQL equivalente exigiria JOINS recursivos em milhões de linhas

Os mesmos 4 gatilhos já mencionados no slide do Gargalo Relacional — agora implementados em código.

O Futuro da Segurança Bancária

A transição do modelo relacional para grafos não é uma preferência técnica — é uma necessidade operacional diante da escala e velocidade do crime financeiro organizado.

Modelo Relacional

- Junções complexas e custosas
- Detecção tardia, após o prejuízo
- Inviável em tempo real
- Fraudes classificadas erroneamente como dívida comum

Banco de Dados em Grafo

- Navegação por ponteiros físicos via Index-Free Adjacency
- Detecção na criação da conta ou do pedido
- Complexidade linear $O(V+E)$
- Intercepta a fraude antes do prejuízo se efetivar

Ao focar na relação entre os dados — e não nos registros isolados —, instituições financeiras conseguem interceptar fraudes complexas de identidade e e-commerce em tempo real, mitigando prejuízos antes mesmo que eles sejam consolidados.

Fontes de Pesquisa e Referências

- Neo4j Team (2014). Fraud Detection Using GraphDB: Discovering Connections with Graph Database Technology. Available at: https://drive.google.com/file/d/19A4hdJhV8c62VpxMS6FArznnGR81wogz/view?usp=drive_link
- Kumar, N., & Singh, K. (2016). Analysis of Pattern Identification Using Graph Database for Fraud Detection. International Journal of Computer Science Journal, Vol. 9, No. 2. Available at: <https://www.computerscijournal.org/vol9no2/analysis-of-pattern-identification-using-graph-database-for-fraud-detection/>