

Detecção de Fraudes Bancárias via Teoria dos Grafos

Superando as limitações dos sistemas relacionais na era digital.

· Pedro Henrique Freire Gama · Pedro Affonso Lopes Dias · Sofia Pacheco Rizzotto · Vitor Gabriel da Silva Santos

O Desafio da Fraude em Tempo Real

Fraudadores exploram vulnerabilidades com precisão, tornando a detecção tardia e o prejuízo inevitável. Bancos de dados relacionais são incapazes de mapear conexões ocultas em tempo real — criando a necessidade de uma nova abordagem estrutural.

Adversários Especializados

Grupos organizados exploram brechas sistêmicas antes que qualquer alerta seja gerado.


Limitação Relacional

Junções complexas e custosas impossibilitam análise de vínculos em tempo real.

Solução em Grafos

Navegação por conexões na memória permite detecção imediata de padrões fraudulentos.

Fraude de Primeira Ordem: Identidades Sintéticas



Fraudadores solicitam crédito sem garantia sem intenção de pagar, comportando-se como clientes legítimos até desaparecerem com os recursos.

- **10–20%** da dívida incobrável em grandes bancos dos EUA e Europa é fraude não classificada
- Relação **exponencial** entre participantes da quadrilha e valor total controlado
- Padrões de conexão revelam a rede — característica explorável por grafos

Figura 1: 2 pessoas compartilhando 2 dados e criando 4 identidades sintéticas. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

O Gargalo Computacional do Modelo Relacional

A natureza combinatória do golpe escala rapidamente: com 10 pessoas e 3 instrumentos por identidade falsa, são geradas **100 identidades** e um prejuízo próximo a **US\$ 1 milhão**.

Bancos relacionais exigem junções complexas e custosas — inviáveis em tempo real. Bancos em grafos navegam conexões na memória, permitindo consultas em quatro estágios críticos:

01

Criação da conta

02

Durante investigação

03

Atingimento do limite de crédito

04

Devolução de cheque sem fundos




Figura 2: Subconjunto de uma rede de fraude, conforme modelado em um banco de dados gráfico. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

Fraude de Seguros: Colisões Encenadas e Permutações




Diagram 5: Simple 6-people collusion

Quadrilhas organizam prestadores de serviços (advogados, médicos, mecânicos) e participantes de acidentes falsos para reivindicações fraudulentas de alto valor.

Escala Combinatória

10 pessoas forjam 5 acidentes com permutação de papéis: cada um age como motorista 1 vez e passageiro 3 vezes.

Impacto Financeiro

Com indenização média de US\$ 40 mil por pessoa e US\$ 5 mil por veículo, a quadrilha reivindica até **US\$ 1,6 milhão.**

Figura 3: Conluio simples de 6 pessoas. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

Revelando Relações Ocultas através do Caminhamento

Criminosos encenam conflitos complexos que só se tornam evidentes por análise de conexões em grafos, revelando relações entre pessoas que aparentam ser estranhas.

Em bancos relacionais, seria necessário unir tabelas de acidentes, veículos, proprietários, motoristas, passageiros e testemunhas repetidamente — operação inviável. Em grafos, é uma simples questão de **caminhamento**, integrável às verificações padrão no momento da solicitação de indenização.




Figura 4: Uma representação gráfica de fraude em seguros. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB

E-commerce: Multi-Identities e Vínculos Digitais




Figura 5: Fraude de pagamento online originada de endereço IP. Origem da imagem: Artigo Neo4j - Detecção de Fraudes Usando GraphDB



IP Compartilhado

Múltiplos usuários com transações no mesmo IP sugerem identidades falsas coordenadas.



Cartão com Múltiplos Endereços

Um cartão associado a diferentes endereços de entrega indica uso fraudulento.



Endereço com Múltiplos Cartões

Um endereço vinculado a vários cartões revela esquemas de multi-identidade.

Fraudadores criam múltiplas identidades para explorar sistemas de pagamento online. A relação esperada entre identificadores é **1:1** — desvios indicam fraude.

Verificações integradas a eventos de **login**, **pedido** e **registro de cartão** tornam o sistema altamente eficiente.

Como Funciona a Infraestrutura do Banco de Dados em Grafo?

01

Criação do Grafo e Definição de Regras

Primeiro, criamos um banco de dados de grafos a partir de um banco de dados estruturado adicionando propriedades aos nós e definindo o relacionamento entre eles. Isso origina um algoritmo de consulta para a recuperação de um subgrafo e, por meio da análise de fraudes, definimos regras para identificar tendências fraudulentas.

02

Consulta e Estabelecimento de Relações

Em seguida, faz-se necessário consultar um banco de dados existente para identificar as propriedades interessantes do grafo e estabelecer relações entre elas, armazenando os dados em nós, enquanto as arestas representam as relações entre eles.

03

Otimização com Neo4j e Index-Free Adjacency

Assim, a partir da utilização da estrutura fundamental de um grafo, podemos obter padrões comuns nos dados. O banco de dados de grafos comumente utilizado, o Neo4j, melhora substancialmente o tempo de resposta por não precisar realizar uma busca em todos os dados, mas sim apenas em ponteiros físicos, pois cada nó conhece os seus próprios vizinhos. Esta última característica é a Index-Free Adjacency.

Algoritmos de Mineração de Padrões (Graph Mining)

Alguns dos algoritmos existentes utilizados na descoberta desses dados destacam-se como:

Algoritmo Part Miner

Todos os grafos no banco de dados são divididos em subgrafos menores. O Part Miner pode reduzir efetivamente a quantidade de grafos candidatos examinando os dados totais das unidades, levando a uma economia considerável de custos e sendo eficiente e flexível na descoberta de subgrafos.

Algoritmo gSpan

Consegue descobrir subestruturas regulares sem a geração de candidatos. Desenvolve-se uma nova ordem lexicográfica entre os grafos e direciona-se cada grafo para um código DFS mínimo exclusivo como rótulo canônico. O gSpan explora a abordagem DFS para investigar subgrafos regulares conectados de forma eficaz, superando o FSG (Frequent Subgraph Mining).

Algoritmo gIndex

Utiliza subestruturas regulares como propriedade básica de categorização ou indexação. Subestruturas regulares tendem a ser ótimas candidatas, visto que exploram os atributos internos da informação e são estáveis a atualizações no banco de dados, criando uma indexação e padronização.

Algoritmo R-MAT

Sistema recursivo específico de geração de grafos sintéticos a partir de um conjunto de grafos reais. O sistema de matriz recursiva (R-MAT) pode gerar grafos precisos registrando a importância de cada grafo em poucas variáveis, facilitando a geração de grafos ponderados, direcionados e bipartidos com traços de redes reais, sendo uma base de dados massiva para testes.

Otimização por Colônia de Formigas (ACO) em Grafos




Figure 1. Traversal of Ants in Multilayered graph

Explicação da abordagem ACO inspirada no comportamento de busca por alimento de formigas, com marcação de feromônios.

- **Inspiração Biológica:** O algoritmo se baseia no comportamento de formigas reais, que depositam feromônios no solo para sinalizar caminhos promissores aos outros membros da colônia.
- **Procedimento Computacional:** Uma colônia de N formigas virtuais parte de um nó inicial e percorre o grafo camada por camada, realizando uma busca semelhante à busca em largura (BFS).
- **Regra de Transição:** A cada ciclo, as formigas escolhem nós específicos com base em regras de transição de estado, conectando esses pontos para formar caminhos candidatos.
- **Identificação do Padrão:** No início, todos os caminhos têm a mesma preferência. Após múltiplos ciclos, o subgrafo/caminho ideal de fraude é revelado por aquele que acumular a maior concentração de feromônio.

Figura 6: Percurso de formigas em grafos multicamadas.
Origem da imagem: Computer Science Journal - Analysis of
Pattern Identification Using Graph Database for Fraud
Detection

O Futuro da Segurança Bancária

A transição do modelo tradicional de bancos de dados relacionais para os sistemas orientados a grafos representa uma evolução estratégica indispensável no combate ao crime financeiro organizado. Ao focar na relação e na interconexão entre os dados em vez de analisar registros isolados, as instituições conseguem interceptar fraudes complexas de identidade, seguros e e-commerce em tempo real, mitigando prejuízos antes mesmo que eles sejam consolidados de fato.

Fontes de Pesquisa e Referências

- Neo4j Team (2014). Fraud Detection Using GraphDB: Discovering Connections with Graph Database Technology. Available at: <https://we-yun.com/doc/neo4j-book/%E5%9B%BE%E6%95%B0%E6%8D%AE%E6%8D%AE%E5%BA%93%E5%9B%9B%E5%BA%94%E7%94%A8%E6%A1%8B%E4%BE%8B/Fraud%20Detection%20Using%20GraphDB%20-%202014.pdf>
- Kumar, N., & Singh, K. (2016). Analysis of Pattern Identification Using Graph Database for Fraud Detection. International Journal of Computer Science Journal, Vol. 9, No. 2. Available at: <https://www.computerscijournal.org/vol9no2/analysis-of-pattern-identification-using-graph-database-for-fraud-detection/>